Engenharia de dados aplicado à COVID 19

01.

DESENVOLVIMENTOS

Explicação e Funcionamento do back-end, Databricks e Front-end.

02.

EVOLUÇÃO DA SOLUÇÃO

Melhorias possíveis e lições aprendidas.

DESENVOLVIMENTOS

Back-End

Requisição de informações via API, verificação da informação e inserção no banco de dados

Databricks

Extração da informação do banco de dados, transformação, testes de hipóteses e insights

Power BI

Dashboards com informaçoes e indicadores dos casos de Covid no mundo/Brasil.

ARQUITETURA BACK-END

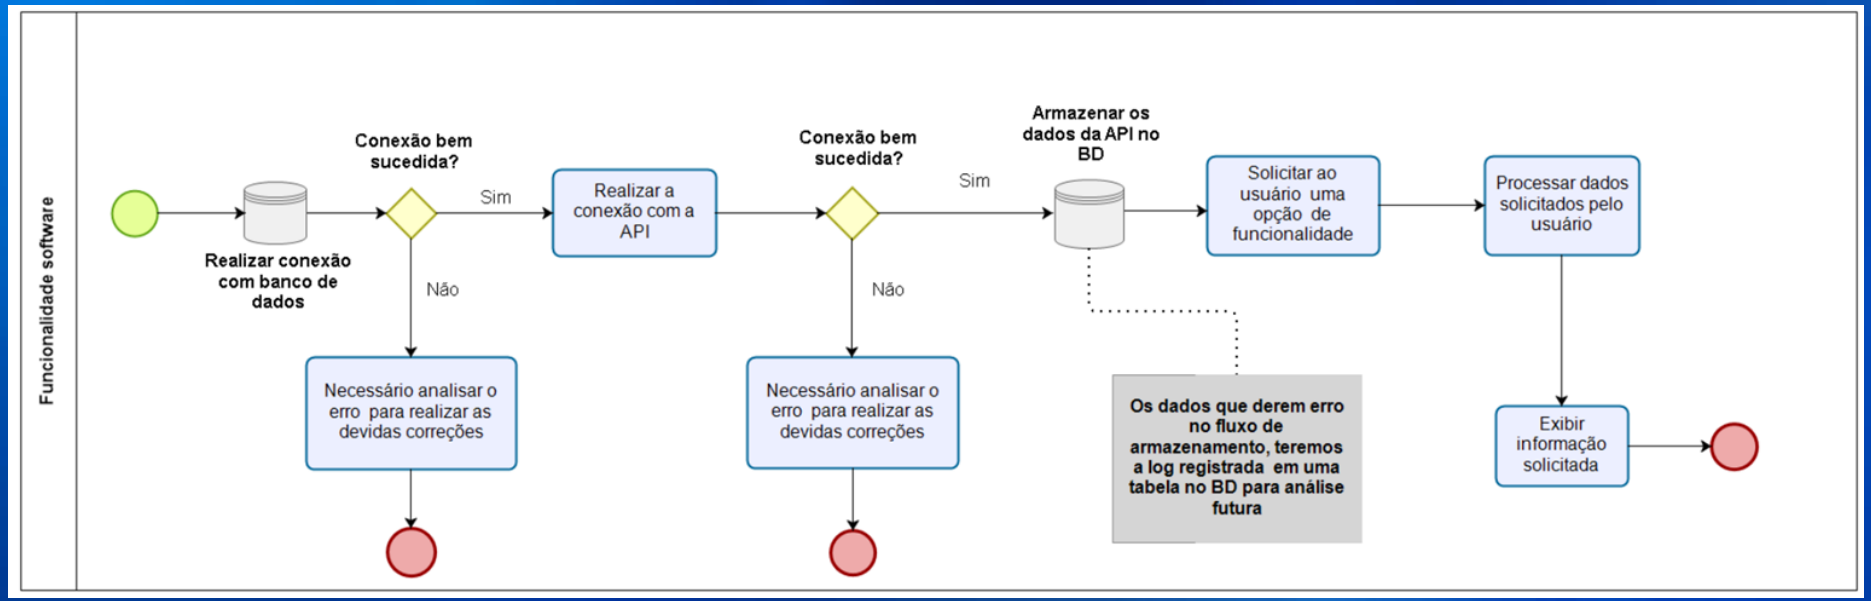

ESTRUTURA DO SOFTWARE - BACK-END

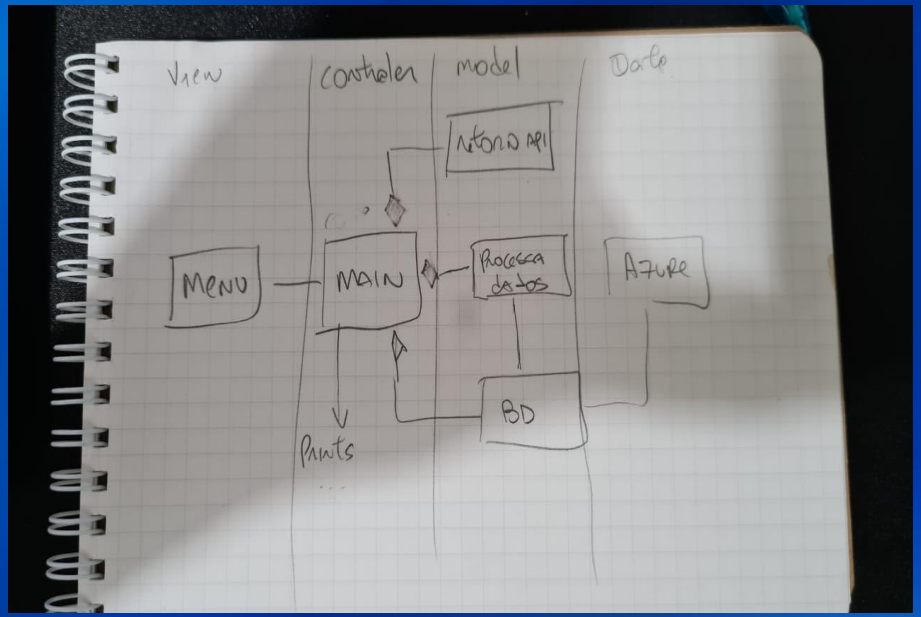

FUNCIONALIDADE FRONT-END

Divisão dos Notebooks

Ingestão

Realizar a ingestão dos datasets que estão no banco SQL na Azure em um diretório de arquivos raw dentro do DBFS.

Cmd 2

Configuração para acesso ao banco de dados

OBS: Não esquecer de liberar o IP do Databricks nas configurações do banco no Azure.

Cmd 3

```
jdbcHostname = "datazilla.database.windows.net"
jdbcDatabase = "datazilla"
jdbcPort = 1433
jdbcUrl = "jdbc:sqlserver://{0}:{1};database={2}".format(jdbcHostname, jdbcPort, jdbcDatabase)
connectionProperties = {
  "user" : 'datazilla',
  "password" : 'gama123456@#$',
  "driver" : "com.microsoft.sqlserver.jdbc.SQL
}
```

Transformações

Cmd 1

Realizar transformações nos datasets, de modo a converter o dado ingestado previamente no formato mais otimizado para Big
fisicamente quando necessário.

Cmd 2

Transformação das tabelas de formato JSON para Parquet

Cmd 3

Definindo um schema para cada tabela

Cmd 4

```
from pyspark.sql.types import StructType, StructField, StringType, IntegerType, DateType
```

Carregamento dos dados em parquet

Cmd 2

```
df_data_by_country = spark.read.parquet("dbfs:/FileStore/_covid_data_lake/_ready/_data_by_country/data_by_country.parquet")
df_summary_country = spark.read.parquet("dbfs:/FileStore/_covid_data_lake/_ready/_summary/summary_country.parquet")
```

Cmd 3

Análise exploratória dos dados

Aqui realizaremos uma série de queries sobre os dados

Cmd 4

Comparação do número de casos do Brasil com outros três 'epicentros' da COVID-19

Cmd 5

```
import pyspark.sql.functions as f
```

FUNCIONALIDADE FRONT-END

Conexão com PowerBI

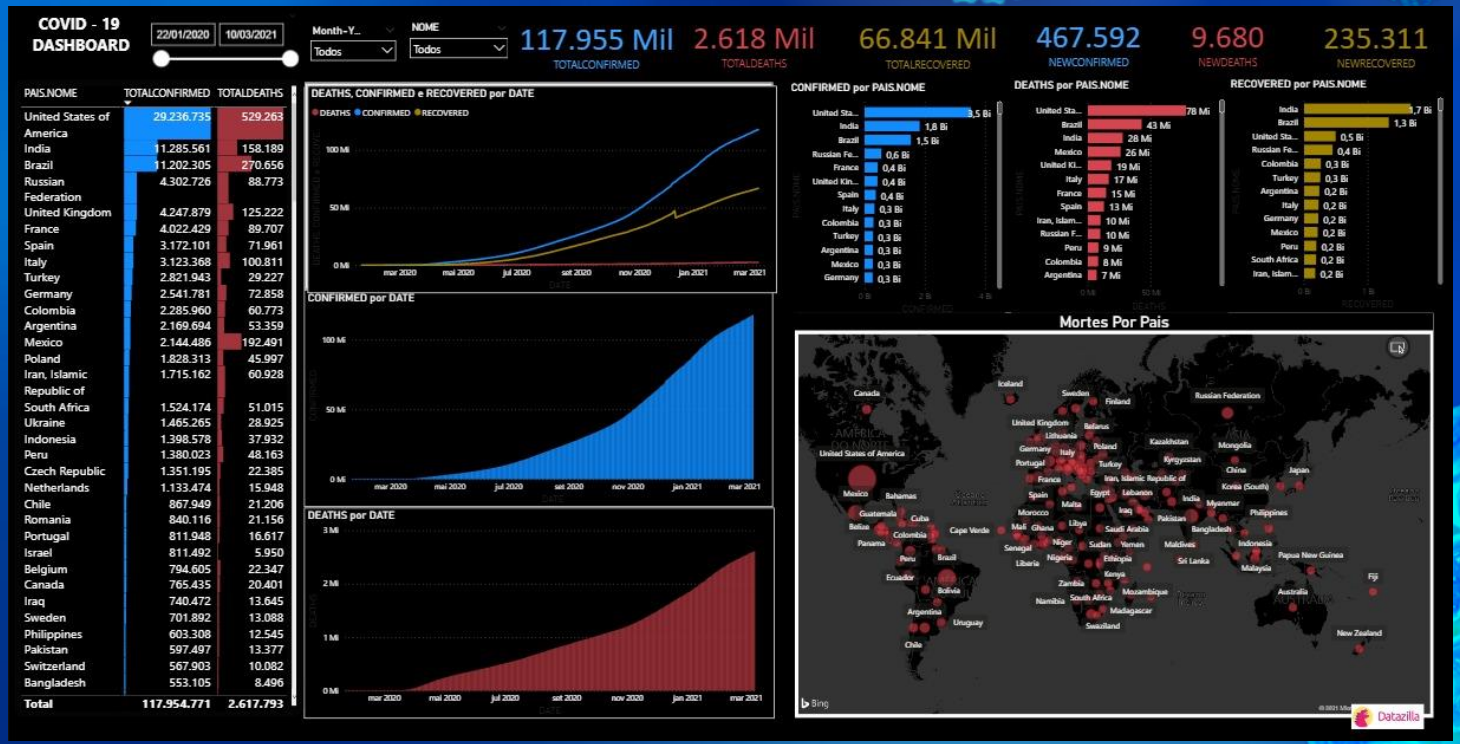

DIFICULDADES E LIÇÕES APRENDIDAS

- API Instável - Foi necessário criar caches em disco e trabalhar extensivamente com exceções
- Validar os tipos criando Schema de dados no DataFrame
- Processar os dados antes de enviar verificando duplicidade através de Timestamp e Nomes dos Países, criando o relacionamente de chaves
- Conexão de internet Instável forçou inserir linha a linha, fazendo commits depois de um número de inserts (ao invés de se utilizar funções otimizadas para muitos inserts)
- Maior controle para o usuário, fragmentando as tarefas e possibilitando ao usuário faze-las de acordo com a necessidade
- Foco na Qualidade, Desenvolvimento para “outra” equipe, Boas Práticas de Design

OBRIGADO!

GRUPO 2 – Datazilla
Deive Audieres Leal
Gabriel Ballesteros
George Razera
Judson Santana
Leonardo Moreno Giantin Rodrigues
Tiago Fernandes DAgostino
Viviane Jordão Nyitray

CREDITS: This presentation template was created by Slidesgo, including icons by Flaticon, and infographics & images by Freepik